

# 可穿戴设备上的深度学习

## 可穿戴设备上的深度学习

什么是深度学习

常用的深度学习方法

卷积神经网络(CNN)

递归神经网络(RNN)

长短期时间记忆(LSTM)

双向长短期记忆网络(BLSTM)

门控循环单元(GRU)

深度学习在可穿戴设备上的应用

常见的应用方向

三种在可穿戴设备上的深度学习框架类型

总结

参考资料

## 什么是深度学习

深度学习(Deep Learning)是机器学习(Machine Learning)的一种。机器学习分为浅层学习(Shallow Learning)和深度学习。

传统的浅层学习算法

1. 支持向量机
2. 随机森林
3. 条件随机场
4. 神经网络
5. 决策树
6. 感知机

这些算法通常包含一到两层 非线性变换，在面对复杂的场景问题，比如 语音处理、图像识别，存在 表征能力和建模能力 不足的缺点。

即使在浅层学习中，神经网络作为一种灵活的算法，能够通过增加其网络层数来提高表征能力与建模能力，但随着层数的增加，会出现训练困难与过拟合的现象。

深度学习的基本思路，是通过参照人类大脑的神经连接，建立起一个由 多层非线性运算单元 组成的类似的网络结构，往往将较低等级单元的输出作为更高层次单元的输入，通过多个变换阶段分层的方式，对数据特征进行提取与描述，最终得出并表示数据的本质。相比于渐层学习，深度学习的模型有着更多的 非线性操作 的层数，能够通过逐层变换原始数据，实现其从原始数据空间到新特征空间的变换，从而自动学习数据的层次化特征。

感知机带动了神经网络的第一个高潮，但是由于其只能够解决 线性可分问题，对于 非线性问题 与 抑或问题 并没有有效的解决方法。

第一个成功实现的卷积神经网络(CNN)是在1980年由 Fukushima 提出的基于 感受野 的层次结构神经网络模型 Neocognitron。

反向传播算法(BP) 是著名的机器学习算法之一，它在1986年被提出，是一种 非线性连续变换函数的多层感知器的网络参数训练方法。

反向传播算法通过增加神经网络的隐藏层，能够建立更加复杂的数学模型，并且实现对自身网络参数的更新，但由于参数的更新，会出现新的问题，比如求解 非凸的目标损失函数 容易陷入 局部最优 而难以得

到全局最优，同时，残差值在反向传播的过程中会出现 梯度弥散，最终使得靠近输入层的网络参数无法得到有效训练，从而失去了多层数的优势。

## 常用的深度学习方法

1. 限制玻尔兹曼机(RBM)
  1. 深度信念网络(DBN)
  2. 深度玻尔兹曼机(DBM)
2. 深度自编码器(Deep Autoencoder)
3. 稀疏编码(Sparse Coding)
4. 卷积神经网络(CNN)
5. 递归神经网络(RNN)
  1. 长短期时间记忆网络(Long Sort Term Memory)
  2. 双向长短期时间记忆网络(Bidirectional Long Sort Term Memory)
  3. 门控循环单元(GRU)

## 卷积神经网络(CNN)


组成

- 卷积层：对数据进行卷积操作
- 全连通层：顶端
- 线性整流层：在不改变卷积的基础上对神经网络的非线性特性进行增强
- 池化层：压缩数据，降低过拟合的概率
- 损失函数层：在训练过程中用于“惩罚”预测和实际的差异

比较著名的模型有AlexNet和Google的GoogleNet

## 递归神经网络(RNN)

递归神经网络(RNN)自带反馈结构，输出与 当前输入、网络权重、之前的输入 相关。该神经网络是三层架构，包含 输入层、隐藏层 和 输出层。




## 长短期时间记忆(LSTM)

该网络可以记忆长时间的上下文信息，是和对时间序列进行建模。

对于一个以时间为序列基础的数据样本，每个时间步为一个输入向量。

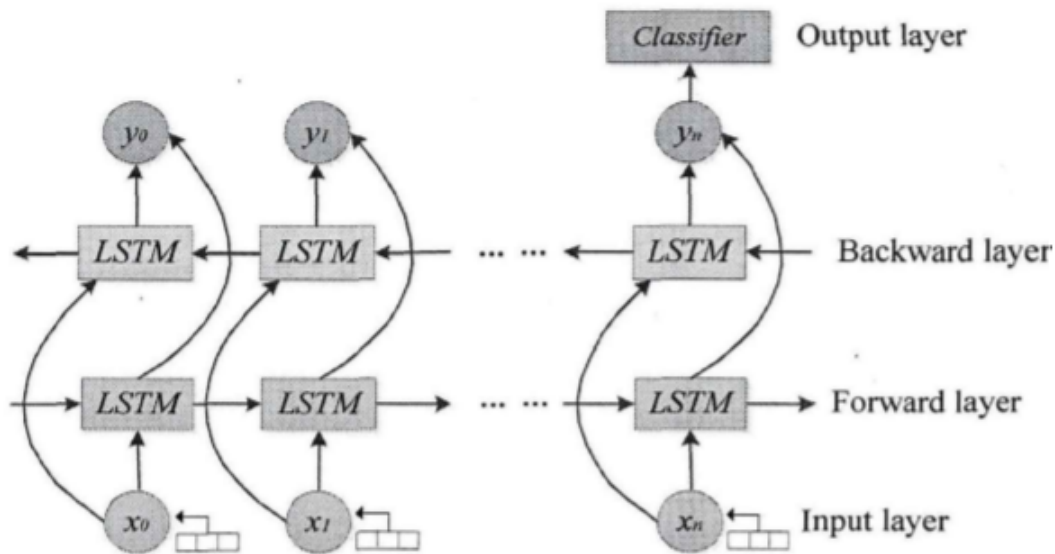
在LSTM网络中，每个节点都存在有记忆能力的储存单元，这些储存单元能够储存之前时刻的输入信息，并且存在一个隐藏的状态用于表示之前输入对当前输出中的影响/权重，即LSTM节点的输出不仅收到当前输入的影响，也与之前时刻的每一个输入有密切关系。在这些节点中，存在着两种控制信息流动的开关——输入门与遗忘门，输入门决定节点需要学习记忆的信息，遗忘门则决定节点需要遗忘删除的信息。



这是一个3层的LSTM模型，层与层之间使用单向连接，每个输入的向量维度为3，时间步长为128，即包含128个向量

## 双向长短期记忆网络(BLSTM)

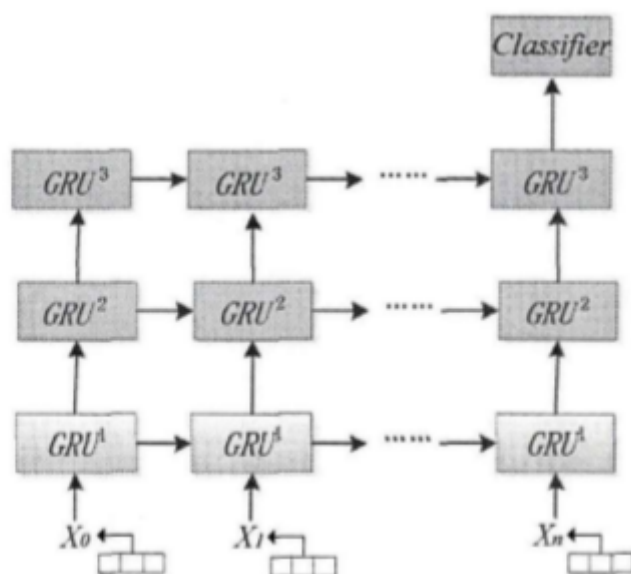
每一个训练序列都有向前和向后两个循环神经网络 (LSTM)，而这两个都连接着一个输出层。这样的结构能够提供完整地保存长时间内的上下文信息，并将这些信息传递到下一输出层。



该模型只含有一层双向递归层，即一个前向LSTM和后向LSTM，每个输入向量维度为3，时间步长128。

## 门控循环单元(GRU)

GRU可以看做是LSTM的一种变体，用于解决RNN因为时间过长而出现的 梯度消失 问题。



输入向量维度3，时间步长128。

## 深度学习在可穿戴设备上的应用

### 常见的应用方向

通常来说，可穿戴设备可以用来监测人的 行为模式 与 身体状况，通过深度学习，能够迅速对其的变化做出个性化反应，从而可以应用在如下几个方面

1. 人机交互：目前主流的人机交互依赖于按键与鼠标等外部设备。但由于各种场景的存在，脱离外设，采用手势/动作/语音等方式来进行人机交互的需求在逐渐扩大。通过摆脱主流的硬件限制，能够更加大幅度解放生产力。微软的hololens与当今的VR(虚拟现实设备)便是在这些需求上进行开发的设备。



2. 身体行为检测：可穿戴设备（智能手环与手表等）相较于传统信息收集设备，有着 低能耗、便携、抗干扰能力强、获取数据方便快捷 等优点；和手机相比，智能可穿戴设备符合人体工学，特化搭载专门的传感器，从而收集到

### 三种在可穿戴设备上的深度学习框架类型




Fig. 5: Three wearable DL execution approaches: offloading nothing, offloading everything, and partial offloading. Offloading nothing means executing all DL task on wearable. Offloading everything means offloading all DL task to handheld. Partial offloading, which is adopted in *CoINF*, means partitioning computation among wearable and handheld.




Fig. 6: Energy consumption of running *Inception* model on LG Urbane and Nexus 6 under different partition scenarios. We only select 20 partition points to present the figure. X-axis presents the layer names that we select as partition point, after which output data are sent to handheld for continuous processing. The left-most bar represents *handheld-only* processing and the right-most bar represents wearable-only processing. The energy consumption of Nexus 6 in this figure is normalized as  $E = \text{original\_}E / \text{Nexus6\_capacity} \times \text{Urbane\_capacity}$ , where *original\_E* is the real consumed energy at handheld, while *Nexus6\_capacity* and *Urbane\_capacity* is the battery capacity of Nexus 6 (3220 mAh) and LG Urbane (410 mAh).

这三种类型基于CoINF的结构

#### 1. 全部在可穿戴设备上实现

- 优点：不依赖其他设备便可以完成任务
- 缺点：对该可穿戴设备的性能要求高，需要设备能够承受住深度学习的框架，同时还要考虑能耗续航问题

#### 2. 全部卸载(offloading)到云端/移动端

- 优点：可穿戴设备性能无要求，只需要采集数据即可
- 缺点：需要外部设备来进行计算，同时对网络有要求

#### 3. 部分在可穿戴设备，部分在云端/移动端


- 优点：能利用上可穿戴设备的性能，同时减轻外部计算设备的负担
- 缺点：需要合理的架构，同时信息传输也有一定的性能要求

## 总结

现在大多的深度学习框架，都含有大量的非线性变换，对于算力有着较高的要求，较大型的工程甚至只能上传到云端，使用更加高性能的计算机或者集群进行运算。

可穿戴设备的由于本身大小的局限，算力很难达到要求，在其本身上难以实现较为复杂的深度学习，因此如今常偏向于使用 可穿戴设备+其他端 作为主流架构。





**Fig. 6.** Intel Edison features a dual-core Intel Atom CPU at 500 MHz, wireless connectivity, and compact physical dimensions at  $35.5 \times 25.0 \times 3.9$  mm. It is a small but powerful platform that is well suited for wearable devices.

随着计算机技术的发展，可穿戴设备能够达到的算力越来越强，如今移动端如手机也能够实现大型计算机的某些功能，即使可穿戴设备无法达到大型计算机或者个人计算机的层次，也能够将来实现一些简单的深度学习的能力。

## 参考资料

1. 基于深度学习与可穿戴传感器的人体行为识别 匡晓华 [https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CMFD&dbname=CMFD201901&filename=1018130494.nh&uid=WEEvREcwSlJHSldRa1FhcEE0QVN2K0s2K084T2JEb05QQ01rR3ZmNjI1ND0=\\$9A4hF\\_YAuvQ5obgVAqNKPCYcEjKensW4IQMovwHtwkF4VYPoHbKxJw!!&v=MjUyMDI0WEZxNUViUEISOGVYMUx1eFITN0RoMVQzcVRyV00xRnJlDVVJMT2VaZWRRxRkNqbFZiLOFWRjI2RnJLN0g=](https://kns.cnki.net/KCMS/detail/detail.aspx?dbcode=CMFD&dbname=CMFD201901&filename=1018130494.nh&uid=WEEvREcwSlJHSldRa1FhcEE0QVN2K0s2K084T2JEb05QQ01rR3ZmNjI1ND0=$9A4hF_YAuvQ5obgVAqNKPCYcEjKensW4IQMovwHtwkF4VYPoHbKxJw!!&v=MjUyMDI0WEZxNUViUEISOGVYMUx1eFITN0RoMVQzcVRyV00xRnJlDVVJMT2VaZWRRxRkNqbFZiLOFWRjI2RnJLN0g=)
2. Enabling Cooperative Inference of Deep Learning on Wearables and Smartphones  
Mengwei Xu, Feng Qian, and Saumay Pushp <https://arxiv.org/pdf/1712.03073.pdf>.
3. Wiki: Convolutional neural network [https://en.wikipedia.org/wiki/Convolutional\\_neural\\_network](https://en.wikipedia.org/wiki/Convolutional_neural_network)
4. A Deep Learning Approach to on-Node Sensor Data Analytics for Mobile or Wearable Devices Daniele Ravelli, Charence Wong, Benny Lo, and Guang-Zhong Yang, Fellow, IEEE <http://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=7797232>